Univerzita Karlova

Přírodovědecká fakulta

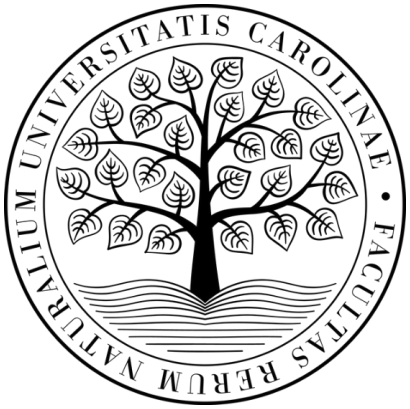


# ÚVOD DO PROGRAMOVÁNÍ

## Odstranění duplicitních prvků z posloupnosti a sdělení jejich počtu

Petra Krsková

3. ročník Geografie a kartografie

Solnice 2022

# Zadání

Na vstupu je nesetříděná posloupnost celých čísel. Nalezněte v posloupnosti duplicitní prvky, odstraňte je a sdělte jejich počet. Pokuste se tuto operaci učinit dostatečně rychle, aby byla metoda použitelná i pro dlouhé posloupnosti (v řádech stovek tisíc prvků). Vstupní data načtěte z textového souboru, výstup uložte také do textového souboru.

Součástí odevzdané úlohy bude zdrojový kód aplikace, vstupní/výstupní data a dokumentace se zadáním v rozsahu 4–5 stran ve formátu PDF obsahující následující:

- rozbor problému
- existující algoritmy
- popis zvoleného algoritmu
- struktura programu (datové struktury, metody,…)
- popis vstupních/výstupních dat
- problematická místa
- možná vylepšení

Aplikace bude považována za nefunkční, pokud:

- při zpracování dat dojde k pádu (runtime chyby, …)
- vrací špatné výsledky
- neřeší možné singulární případy

# Rozbor problému

Posloupnost v matematice představuje sadu objektů, v níž se mohou jednotlivé objekty opakovat a záleží na jejich pořadí. Počet objektů, který může být konečný i nekonečný, je vyjádřen délkou posloupnosti. Posloupnost lze definovat jako funkční vztah mezi množinou přirozených čísel (pozice člena posloupnosti) a jejich obrazem (hodnota členu posloupnosti na dané pozici). Posloupnost bývá označována písmeny ve formě $a_n$, kde dolní index *n* označuje n-tý člen posloupnosti (Wikipedia 2022).

# Existující algoritmy

Pro odstranění duplicitních prvků z posloupnosti existuje několik řešení. První možností je použití FOR cyklu, ve kterém jsou členy původního seznamu představující danou posloupnost čísel porovnávány s novým seznamem. Pokud se v něm nenachází, jsou do něj přiřazeny a na konci cyklu tak uživatel získá nový seznam, ve kterém se prvky z původního seznamu vyskytují právě jednou. Tento způsob je možné zkrátit i do podoby jednoho řádku za použití generátorové notace seznamu (list comprehension). Nejrozšířenější metodou pro odstranění duplicitních prvků je použití funkce *set().* Nejrychlejší variantou je pak využití funkce *collections.OrderedDict.fromkeys()*, která na rozdíl od předchozí zachovává pořadí členů posloupnosti (GeeksforGeeks 2020; JournalDev 2022).

Použitý algoritmus je však založen na prvotním setřídění posloupnosti, čehož lze dosáhnout několika způsoby. Algoritmus *Bubble Sort* je založen na porovnávání sousedních prvků, u kterých dochází k prohození, pokud nejsou ve správném pořadí. Metoda *Merge Sort* nejprve rozdělí posloupnost na dvě poloviny, které pak vzájemně porovnává a ve správném pořadí opět slučuje dohromady. *Insertion Sort* vyhledává správnou pozici prvku ve tříděné posloupnosti. Na začátku porovná první dva prvky a seřadí je. Následně vezme třetí prvek posloupnosti, porovná s dvěma předchozími a zařadí na správnou pozici. Toto je zopakováno pro všechny zbylé prvky posloupnosti. Jednou z možností je také *Shell Sort* založený na rozdělení posloupnosti na menší části a jejich setřídění. Další variantou je *Selection Sort* použitý v tomto případě, který je podrobněji popsán v následující kapitole Tutorialspoint 2022).

# Popis zvoleného algoritmu

Pro eliminaci použití vestavěných funkcí a možnost ukládání konkrétních vymazaných duplicitních hodnot je vstupní posloupnost nejdříve vzestupně setříděna a následně dochází k vypořádání duplicitních hodnot. Pro setřídění posloupnosti byl zvolen algoritmus *Selection*

*Sort*, který je založen na procházení seznamu a nalezení nejmenší hodnoty. Tato hodnota je zařazena na začátek setříděného seznamu a tento proces je opakován pro všechny zbývající prvky v dosud nesetříděném seznamu. Každý nově přiřazený prvek do již setříděného seznamu je nejprve porovnán s ostatními prvky a poté zařazen na odpovídající pozici.

V takto setříděné posloupnosti jsou pak postupně procházeny jednotlivé prvky a porovnávány se sousedními. Pokud se nerovnají a daný prvek se již nevyskytuje v seznamu odpovídající výsledné posloupnosti, je do ní přiřazen. V opačném případě se jedná o duplicitní prvky a aktuální prvek je tak uložen do příslušného slovníku jako klíč, případně je zde jeho hodnota zvýšena o jedna. Tím je docíleno zaznamenání všech duplicitních prvků i toho, kolikrát navíc se v posloupnosti vyskytovaly.

## Pseudokód zvoleného algoritmu

***Funkce SortList (input_list)***

***cyklus*** *procházení pozic i seznamu hodnot*
***min*** *= počáteční pozice*
***cyklus*** *procházení pozic hodnot od i+1*
***pokud*** *je hodnota na pozici menší než na min*
***zápis*** *hodnoty do min*
***prohození*** *minimální hodnoty s porovnávanou hodnotou*
***navrácení*** *input_list*

***Funkce DeleteDuplicates (input_list)***

*final_list = nový seznam*
*dictionary = nový slovník*
*i = inicializace na hodnotu 0*
***dokud*** *je i menší než délka seznamu menší o 1*
*j = i+1*
***pokud*** *se hodnoty na pozicích i a j nerovnají a zároveň první není ve final_list*
***připojení*** *hodnoty na pozici i do seznamu final_list*
***zápis*** *hodnoty do výstupního souboru*
***jinak***
***vytvoření*** *klíče z hodnoty nebo zvýšení jeho hodnoty o 1*
*zvýšení i o 1*

*max = délka vstupního seznamu menší o 1*
***pokud*** *hodnota na pozici max není ve final_list*

***připojení*** *hodnoty do final_list*

***zápis*** *hodnoty do výstupního souboru*

***navrácení*** *final_list, dictionary*

# Struktura programu

Program sestává z 89 řádek včetně komentářů a odsazení a obsahuje pět metod.

První metoda *SequenceFromFile* slouží pro otevření souboru a načtení vstupních dat. Pomocí *try* a *except* bloků je odchytáván špatně zadaný název souboru či cesta k jeho umístění, nedostatečné oprávnění pro přístup k souboru a další případné chyby spojené s otevíráním a čtením souboru. V případě chyby je do konzole vypsána chybová hláška definující problém a program skončí. Po otevření souboru je také zkontrolováno, zda obsahuje nějaká data a v případě prázdného souboru je opět vypsána chybová hláška a program skončí. Funkce vrací seznam hodnot typu *string* načtených ze souboru.

Druhá metoda *WriteToFile* slouží pro zápis výsledné posloupnosti čísel a duplicitních prvků do výstupního souboru. Podobně jako v předchozí metodě jsou zde pomocí *try* a *except* bloků ošetřeny možné chyby při otevírání souboru. Výstupní soubor je otevřen v módu *a*, který umožňuje připisování dat na aktuální konec souboru a nedochází tak k přepisu již existujících dat.

Třetí metoda *StrToInt* převádí seznam s hodnotami typu *string* na seznam s hodnotami typu *integer*. Toho je docíleno pomocí cyklu, který postupně prochází prvky seznamu a převádí je. Pokud narazí na prvek, který není číslem a nejde tak převést na datový typ *integer*, vypíše chybovou hlášku a daný prvek přeskočí.

Čtvrtá metoda *SortList* slouží k vzestupnému setřídění posloupnosti. Algoritmus této metody je podrobněji popsán v předchozí kapitole, ale je založen na *for* cyklu s vnořeným druhým cyklem, který prochází dosud nesetříděné prvky a vybírá z nich minimum.

Pátá metoda *DeleteDuplicates* prochází sousední prvky seznamu a kontroluje, zda se rovnají. Pokud ne a první porovnávaný prvek se již nevyskytuje ve výstupním seznamu, je do něj připojen. V opačném případě je z prvku vytvořen klíč ve slovníku, případně je zde jeho hodnota zvýšena o jedna. Na závěr dochází ke kontrole, zda se poslední prvek vstupního seznamu nachází i ve výstupním seznamu a případně je sem doplněn.

V hlavní části programu je do seznamu *sequence* načtena posloupnost ze vstupního seznamu, jejíž hodnoty jsou zároveň převedeny na datový typ *integer* a setříděny. Následně je vytvořen seznam *final* a slovník *duplicates*, do kterých jsou uloženy výstupy funkce *DeleteDuplicates*.

V poslední části programu je pak do výstupního souboru zapsán celkový počet odstraněných duplicitních prvků posloupnosti. Toho je docíleno součtem všech hodnot ve slovníku *duplicates.* Následně jsou pomocí *for* cyklu procházeny klíče a hodnoty v tomto slovníku, které odpovídají vymazaným duplicitním prvkům a jejich počtu, a funkcí *WriteToFile* jsou zapsány do výstupního souboru.

# Vstupní a výstupní data

Program načítá vstupní data z textového souboru s názvem *input.txt*, který obsahuje na první řádce všechny celočíselné prvky posloupnosti oddělené mezerou. Při jiném názvu souboru je potřeba změnit kód na řádce 83, v závorce změnit název souboru či upravit cestu k jeho umístění. Pokud by byly od sebe prvky odděleny jiným znakem, je potřeba upravit kód programu na řádce 10 a to tak, že se daný znak zapíše do uvozovek do závorky funkce *split().*

Výslednou posloupnost a odstraněné duplicitní znaky včetně informace o tom, kolikrát byly vymazány, jsou zapisovány do textového souboru s názvem *output.txt*. Obdobně jako u vstupního souboru je v případě jiného názvu nutné upravit kód na řádkách 70, 79 a 89. Pro oddělení prvků výsledné posloupnosti jinak než mezerou je potřeba upravit kód na řádce 70 a to tak, že se v části *f"{element} "* mezera za složenou závorkou nahradí požadovaným znakem.

# Problematická místa a možná vylepšení

Problematické může být zapisování do souboru v módu *append*, kdy dochází k připisování na konec souboru a časem je zde tak velké množství výstupů. Řešením by bylo nezapisovat prvky výsledné posloupnosti jednotlivě zároveň s jejich připojením do seznamu *final* a podobně jednotlivých klíčů a hodnot slovníku *duplicates,* ale místo toho otevírat výstupní soubor v módu *write* a *final* i *duplicates* do něj zapisovat celé najednou.

Pro zkrácení a zjednodušení programu by bylo možné vynechat funkci *StrToInt*, která je založena na *for* cyklu, který prochází všechny prvky posloupnosti a převádí je z datového typu *string* na *integer*. Stejného výsledku by bylo možné docílit například použitím funkce *map()* při načítání dat ze souboru. Tato možnost však neumožňuje upozornit na konkrétní chybné prvky a přeskočit je, tudíž by program skončil i při výskytu jen jednoho nečíselného prvku v posloupnosti.

# Zdroje

GEEKSFORGEEKS (2020): Python – Ways to remove duplicates from list, https://www.geeksforgeeks.org/python-ways-to-remove-duplicates-from-list/ (5.2.2022).

JOURNALDEV (2022): Python Remove Duplicates from a List, https://www.journaldev.com/32742/python-remove-duplicates-from-list (5.2.2022).

TUTORIALSPOINT (2022): Python - Sorting Algorithms, https://www.tutorialspoint.com/python_data_structure/python_sorting_algorithms (7.2.2022).

WIKIPEDIA (2022): Sequence, https://en.wikipedia.org/wiki/Sequence (5.2.2022).